

- **AI/ML/DL han revolucionado la medicina y la salud:**
 - **Imágenes médicas**
 - **Investigación en medicina**
 - **Desarrollo del genoma**
- **El Deep learning ha demostrado ser mejor en la detección y clasificación de enfermedades gracias a las imágenes médicas.**
- **El cáncer de piel puede ser detectado de forma más precisa gracias al Deep Learning que por los dermatólogos (2018).**
 - **Detección por parte de dermatólogos = 86.6%**
 - **Detección por Deep Learning = 95%**

Referencia: "Computer learns to detect skin cancer more accurately than doctors". The Guardian. 29 May 2018




- En este caso práctico, trabajaremos como consultor de Deep Learning.
- Hemos sido contratados por un hospital de un barrio de Toronto y nos han encomendado la tarea de automatizar el proceso de detección y clasificación de las enfermedades de pecho para reducir el coste y tiempo de detección
- El equipo ha recopilado muchos Rayos X de pecho y nos pide detectar y clasificar enfermedades en menos de 1 minuto.
- Nos han entregado 133 imágenes que pertenecen a 4 categorías:
 - Sano
 - Covid-19
 - Pneumonía Bacterial
 - Pneumonía Vírica




REDES NEURONALES DE CONVOLUCIÓN

- Las primeras cappingas de una CNN se usan para extraer características generales de alto nivel.
- Las últimas capas se usan para llevar a cabo una tarea de clasificación específica.
- Los campos locales respectivos escanean la imagen para buscar formas como líneas o bordes.
- Estos bordes son seleccionados por las capas subsiguientes para formar características más complejas.



REDES NEURONALES DE CONVOLUCIÓN



HISTORIA DEL DEEP LEARNING


- Hay muchas REDES NEURONALES DE CONVOLUCIÓN ya entrenadas y disponibles como por ejemplo:
 - LeNet-5 (1998): red convolucional de 7 niveles desarrollada por LeCun que funciona identificando dígitos escritos a mano
 - AlexNet (2012): Ofrece una mejora masiva, con reducción del error del 26% al 15.3%
 - ZFNet (2013): bajó el error al 14.8%
 - GoogLeNet/Inception (2014): reduce el error al 6.67% que es similar a la precisión que obtendría un humano
 - VGGNet (2014)
 - ResNet (2015): Residual Neural Network incluye capas de “skip connection” y permite entrenar 152 capas sin problemas de desvanecimiento del gradiente. El error es del 3.57% muy superior al de un humano.

Source: <https://medium.com/analytics-vidhya/cnns-architectures-lenet-alexnet-vgg-googlenet-resnet-and-more-666091488df5>



RESNET (RESIDUAL NETWORK)

- A medida que las CNNs son más profundas, aparece el problema del desvanecimiento del gradiente, que impacta negativamente en la eficacia de la red neuronal para llevar a cabo su tarea.
- El desvanecimiento del gradiente ocurre cuando propagamos el gradiente hacia atrás muchas capas que hace que su valor sea muy pequeño.
- La red neuronal residual incluye una característica de “skip connection” que permite entrenar 152 capas sin el problema del desvanecimiento
- Resnet trabaja añadiendo “identity mappings” encima de la CNN.
- ImageNet contiene 11 millones de imágenes y 11,000 categorías.
- ImageNet se usa para entrenar redes profundas ResNet.




¿QUÉ ES EL APRENDIZAJE POR TRANSFERENCIA

- El aprendizaje por transferencia es una técnica de aprendizaje automático en la que una red que ha sido entrenada para realizar una tarea específica se reutiliza como punto de partida para otra tarea similar.
- El aprendizaje por transferencia se usa ampliamente, ya que partir de modelos previamente entrenados puede reducir drásticamente el tiempo de cálculo requerido respecto de si el entrenamiento se realiza desde cero.



TRANSFERENCIA DE
APRENDIZAJE



- Photo Credit: https://commons.wikimedia.org/wiki/File:Lillehammer_2016_-_Figure_Skating_Men_Short_Program_-_Camden_Pulkinen_2.jpg
- Photo Credit: https://commons.wikimedia.org/wiki/Alpine_skiing#/media/File:Andrej_%C5%A0porn_at_the_2010_Winter_Olympic_downhill.jpg
- Citations: Olga Russakovsky, *Jia Deng*, Hao Su, Jonathan Krause, Sanjeev Satheesh, Sean Ma, Zhiheng Huang, Andrej Karpathy, Aditya Khosla, Michael Bernstein, Alexander C. Berg and Li Fei-Fei.
- ImageNet Large Scale Visual Recognition Challenge. arXiv:1409.0575, 2014.




¿QUÉ ES EL APRENDIZAJE POR TRANSFERENCIA

- “El aprendizaje por transferencia es la mejora del aprendizaje en una nueva tarea a través de la transferencia de conocimiento de una tarea relacionada que ya se ha aprendido” — Transfer Learning, Handbook of Research on Machine Learning Applications, 2009.
- En el aprendizaje por transferencia, se está entrenando una red neuronal artificial base (referencia) en un conjunto de datos y una función base. Luego, estos pesos de red entrenados se reutilizan en una segunda ANN para entrenarse en un nuevo conjunto de datos y función.
- El aprendizaje por transferencia funciona muy bien si las características son generales, de modo que los pesos entrenados se puedan reutilizar de manera efectiva.
- La inteligencia se está transfiriendo desde la red base a la nueva red objetivo.




PROCESO DEL APRENDIZAJE POR TRANSFERENCIA



¿POR QUÉ CONSERVAMOS LAS PRIMERAS CAPAS?

- Las primeras capas de CNN se utilizan para extraer características generales de alto nivel.
- El último par de capas se utilizan para realizar la clasificación (en una tarea específica).
- Entonces, copiamos las primeras capas entrenadas (modelo base) y luego agregamos una nueva capa personalizada en la salida para realizar la clasificación en una nueva tarea específica.



ESTRATEGIAS PARA ENTRENAR USANDO APRENDIZAJE POR TRANSFERENCIA

- **Pasos Estrategia #1:**
 - Congelar los pesos de las primeras capas de la red neuronal convolucional entrenada.
 - Solamente entrenar añadiendo nuevas capas densas (con pesos inicializados aleatoriamente).
- **Pasos Estrategia #2:**
 - Inicializar la CNN con pesos pre entrenados.
 - Retener la CNN al completo configurando un ratio de aprendizaje pequeño, lo cual es crucial para no cambiar demasiado los pesos previamente entrenados.
- **Ventajas del Aprendizaje por Transferencia :**
 - Proporciona un rápido progreso al entrenar pues no hay que empezar desde cero inicializando pesos aleatoriamente.
 - Se pueden usar datasets pequeños para entrenar y aún así conseguir buenos resultados.

