

FinanceGuard Bank

Proyecto de Predicción de Churn de Clientes

Análisis Integral con Machine Learning

Presentado por: Equipo de Data Science

Fecha: Diciembre 2025

Proyecto: Henry - Módulo 4

Agenda

1. Contexto y Objetivo
 2. Datos y Metodología
 3. Modelos Desarrollados
 4. Resultados y Comparación
 5. Segmentación de Clientes
 6. Impacto de Negocio y ROI
 7. Recomendaciones y Próximos Pasos
 8. Preguntas
-

1 Contexto y Objetivo

FinanceGuard Bank - El Desafío

Problema Crítico: - Tasa de churn actual: 20% anual - Pérdida estimada: \$10M/año - Adquirir nuevo cliente: 5-7x más costoso que retener

Objetivo del Proyecto: > Desarrollar un sistema de predicción de churn que permita identificar clientes en riesgo y ejecutar campañas de retención personalizadas

Alcance: - 10,000 clientes analizados - 14 variables predictoras - 3 enfoques de ML (supervisado + no supervisado) - Optimización de costos de negocio

2 Datos y Metodología

Dataset: Churn_Modelling.csv

Características: - 10,000 clientes bancarios europeos (Francia, España, Alemania) - 14 variables: Demográficas, financieras, comportamentales - **Target:**

Exited (0 = No Churn, 1 = Churn) - **Desbalance de clases:** 80% No Churn / 20% Churn

Variables Clave: - **Demográficas:** Edad, Género, Geografía - **Financieras:** Balance, Salario Estimado, Credit Score - **Comportamentales:** IsActiveMember, NumOfProducts, Tenure

Metodología - 3 Avances

Avance 1: Regresión Logística (Baseline)

- Modelo interpretable y rápido
- Identificación de coeficientes significativos
- Establecimiento de línea base

Avance 2: Gradient Boosting (Performance)

- Random Forest, XGBoost, LightGBM, CatBoost
- Optimización con GridSearch y Optuna
- Ensemble con Stacking
- Feature importance detallado

Avance 3: Aprendizaje No Supervisado (Insights)

- Clustering K-Means (4 segmentos)
 - DBSCAN para detección de outliers
 - PCA y t-SNE para visualización
 - Perfiles de clientes por segmento
-

3 Modelos Desarrollados

Portfolio de Modelos (6 modelos entrenados)

Modelo	Tipo	Objetivo
Regresión Logística	Baseline	Interpretabilidad máxima
Random Forest	Ensemble	Baseline robusto
XGBoost	Gradient Boosting	Performance + GridSearch
LightGBM	Gradient Boosting	Velocidad + Accuracy
CatBoost	Gradient Boosting	Manejo de categóricas
Stacking	Meta-Ensemble	Máximo performance

Proceso de Validación: - StratifiedKFold (mantiene proporción de clases)
- Train/Test Split 80/20 - Métricas: Accuracy, Precision, Recall, F1, **ROC-AUC**

4 Resultados y Comparación

Ranking de Modelos por ROC-AUC




Figure 1: Ranking ROC-AUC

Top 3 Modelos:

Posición	Modelo	ROC-AUC	Test Accuracy	Test Recall
	LightGBM	86.99%	86.8%	48.4%
	XGBoost (GridSearch)	86.56%	87.0%	49.4%
	Random Forest	86.56%	87.0%	45.7%

Comparación Integral de Métricas

Insights Principales: - **LightGBM** domina en **ROC-AUC** (métrica de ranking) - **XGBoost** tiene mejor **Recall** (49.4% vs 48.4%) - **Todos los**




Figure 2: Comparación Integral

modelos GB superan ampliamente el baseline - **CatBoost** muestra overfitting (Train 97.8% vs Test 85.4%)

Mejora vs Modelo Baseline

LightGBM vs Regresión Logística

Métrica	Baseline	LightGBM	Mejora
Accuracy	81.0%	86.8%	+5.8 pp
Precision	66.9%	78.5%	+11.6 pp
Recall	25.6%	48.4%	+22.8 pp
F1-Score	37.1%	59.9%	+22.8 pp
ROC-AUC	77.8%	87.0%	+9.2 pp

Impacto Clave: Recall aumenta **89%** → Detectamos casi el doble de churns

Análisis Multidimensional

Interpretación: - **LightGBM:** Más equilibrado, área más grande - **XG-Boost:** Excelente Recall, menor Precision - **Random Forest:** Alta Precision, menor Recall

4

Trade-off Clave: Precision vs Recall - Mayor Recall = Detectamos más churns (menos FN) - Menor Precision = Más falsos positivos (más campañas innecesarias)

Feature Importance - LightGBM

Rank	Feature	Importancia	Insight de Negocio
10	HasCrCard	6.2%	Poseer tarjeta protege

5 Segmentación de Clientes

Clustering K-Means (K=4)

Métricas de Clustering: - Silhouette Score: 0.38 (separación aceptable) - Davies-Bouldin: 1.23 (compacidad buena) - Método: Elbow + Silhouette Analysis

Perfiles de Segmentos

Cluster 0: “Jóvenes Activos” (25.9%)

- **2,587 clientes** | **Churn: 14.3%** (BAJO RIESGO)
- **Perfil:** 38 años, balance \$76K, 1.8 productos, 54% activos
- **Estrategia:** Cross-selling, programa de lealtad preventivo

Cluster 1: “Maduros Comprometidos” (29.4%)

- **2,943 clientes** | **Churn: 19.8%** (RIESGO MODERADO)
- **Perfil:** 43 años, balance \$103K, 2.1 productos, 62% activos
- **Estrategia:** Beneficios VIP, retención premium

Cluster 2: “Seniors Inactivos” (22.2%)

- **2,215 clientes** | **Churn: 23.4%** (ALTO RIESGO)
- **Perfil:** 51 años, balance \$125K, 1.6 productos, 38% activos
- **Estrategia:** Campaña re-engagement URGENTE

Cluster 3: “Desconectados” (22.5%)

- **2,255 clientes** | **Churn: 28.1%** (CRISIS)
- **Perfil:** 47 años, balance \$89K, 1.3 productos, 42% activos
- **Estrategia:** Intervención inmediata, win-back agresivo

Insights de Segmentación

Hallazgos Clave: 1. **Edad + Inactividad = Tormenta Perfecta** - Cluster 2 (seniors inactivos): 23.4% churn - Cluster 3 (desconectados): 28.1% churn




Figure 3: Mejora vs Baseline




Figure 4: Radar Charts




Figure 5: Segmentación

2. **NumOfProducts es crítico:**
 - 1 producto → 25% churn
 - 2 productos → 12% churn (ÓPTIMO)
 - 4 productos → 30% churn (sobresaturación)
 3. **Geografía importa:**
 - Alemania: Mayor riesgo en todos los clusters
 - España: Clientes más leales
 4. **Actividad = Lealtad:**
 - Miembros activos: 10% churn
 - Miembros inactivos: 27% churn (2.7x mayor)
-

6 Impacto de Negocio y ROI

Análisis Económico - Matriz de Costos

Costos Definidos: - **Falso Negativo (FN):** -\$500 (pérdida de cliente) - **Falso Positivo (FP):** -\$50 (campana innecesaria) - **Verdadero Positivo (TP):** +\$350 (retención exitosa neta) - **Verdadero Negativo (TN):** \$0 (sin costo)

Supuestos: - Valor de cliente: \$500/año - Costo de campana: \$50/cliente - Incentivo de retención: \$100 - Tasa de éxito de retención: 40%

Comparación de Escenarios

Escenario 1: Sin Modelo

- Pérdida total: **\$10,000,000/año**
- Clientes perdidos: 20,000
- Sin inversión en retención

Escenario 2: Con Modelo (Threshold 0.5)

- Pérdida neta: **\$8,500,000/año**
- Clientes detectados: 9,680 (Recall 48.4%)
- **Mejora: \$1,500,000 (+15%)**

Escenario 3: Con Modelo (Threshold Óptimo)

- Pérdida neta: **\$8,000,000/año**
 - Clientes detectados: 11,600 (Recall 58%)
 - **Mejora: \$2,000,000 (+20%)**
-




Figure 6: ROI e Impacto

ROI del Proyecto

Inversión vs Retorno (Base: 100,000 clientes)

Concepto	Valor
Inversión Inicial	\$150,000
Desarrollo del modelo	\$80,000
Infraestructura	\$40,000
Implementación	\$30,000
Retorno Año 1	\$2,000,000
Clientes retenidos	4,640
Valor generado	\$2,320,000
Costo de campañas	-\$320,000
ROI Neto	1,233%
Payback Period	0.9 meses

Por cada \$1 invertido, se recuperan \$13.33

Proyección 12 Meses

Beneficio Acumulado: - Mes 1-3: \$500K (Quick wins) - Mes 4-6: \$1.0M (Campañas escaladas) - Mes 7-9: \$1.5M (Optimización continua) - Mes 10-12: \$2.0M (Full operation)

Clientes Impactados: - 4,640 clientes retenidos - \$2.32M en valor protegido - Churn reducido de 20% → 17% (-15%)

7 Recomendaciones y Próximos Pasos

Plan de Acción: 0-30 Días (Acción Inmediata)

1. Deploy del Modelo LightGBM

- Implementar scoring semanal
- Dashboard con top 1,000 clientes en riesgo
- Alertas automáticas (score >0.7)

2. Campañas por Cluster

Cluster 3 (Crisis - 28.1% churn): - Contacto telefónico personal - Waive fees 3 meses + \$100 cashback - KPI: Reducir churn a 20%

- Cluster 2 (Seniors - 23.4% churn):** - Campaña re-engagement multicanal
- Simplificación app + tutorial - KPI: Incrementar actividad 30%
-

Plan de Acción: 1-3 Meses (Corto Plazo)

3. Optimización de Threshold

- Implementar threshold dinámico por cluster
- A/B testing: threshold 0.5 vs óptimo
- Ajuste según costos reales observados

4. Features de Clustering

- Re-entrenar modelo con 5 features derivadas
- Esperado: +2-5 pp en accuracy
- Validación con grupo de control

5. Sistema de Early Warning

- Predicción en múltiples horizontes (30/60/90 días)
 - Alertas progresivas ()
 - Integración con CRM
-

Plan de Acción: 6-12 Meses (Mediano Plazo)

6. Modelos Especializados

- Entrenar 4 modelos (uno por cluster)
- Hipótesis: +3-5 pp accuracy
- Personalización extrema

7. Feature Engineering Avanzado

- Features temporales (tendencias)
- Features de interacción
- Datos transaccionales en tiempo real

8. Integración End-to-End

- Pipeline automático: datos → modelo → acción
 - Cierre del loop: medir impacto real
 - Optimización continua basada en resultados
-

KPIs de Éxito

Métricas Técnicas:

- Model Accuracy: Mantener >86%
- Recall: Incrementar de 48% a 60% en 6 meses
- ROC-AUC: Mantener >87%

Métricas de Negocio:

- Tasa de churn global: Reducir de 20% a 17% (-15%)
- Clientes retenidos: +400/mes
- Revenue protected: \$2M/año
- ROI campaña retención: >250%

Métricas de Proceso:

- Tiempo de respuesta a alerta: <24h
 - Tasa de contacto exitoso: >70%
 - Satisfacción campaña retención: >4/5
-

8 Conclusiones Finales

Logros del Proyecto

Técnicos:

1. **Modelo Campeón identificado:** LightGBM (87% ROC-AUC)
2. **Mejora de 89% en detección** vs baseline (Recall: 25.6% → 48.4%)
3. **Segmentación estratégica:** 4 clusters con insights accionables
4. **Threshold optimizado:** Mejora adicional del 5-10% en ROI

De Negocio:

1. **\$2M de valor anual protegido**
 2. **ROI de 1,233%** en primer año
 3. **4,640 clientes retenidos adicionales**
 4. **Reducción proyectada del churn: 20% → 17%**
-

Aprendizajes Clave

1. Gradient Boosting > Modelos Lineales

- LightGBM supera a Regresión Logística en todas las métricas
- Captura relaciones no lineales complejas

- Feature importance automatizado

2. Clustering Complementa Supervisado

- Segmentación revela patrones ocultos
- Estrategias personalizadas por cluster
- Features derivadas mejoran modelos supervisados

3. Threshold 0.5

- Optimizar según costos de negocio es crítico
- Puede generar 5-15% mejora adicional en ROI
- Debe ser dinámico y monitoreado

4. Edad + Actividad = Factores Críticos

- Top 2 features en todos los modelos
- Combinación edad >45 + inactividad = 3x riesgo
- Accionable: Campaña de activación focalizada

Impacto Esperado en 12 Meses

Sin el Proyecto: - 20,000 clientes perdidos - \$10M en pérdidas - Sin capacidad de prevención

Con el Proyecto: - 15,360 clientes perdidos (-23%) - \$8M en pérdidas (-20%) - 4,640 clientes salvados - Sistema predictivo operativo - Aprendizaje continuo

Reducción del 23% en abandono = \$2M recuperados

Siguientes Niveles

Para el Negocio:

- Expandir a otros productos (tarjetas, préstamos)
- Aplicar framework a customer acquisition
- Desarrollar Customer Lifetime Value (CLV) prediction

Para el Modelo:

- Incorporar datos externos (economía, competencia)
- Deep Learning con secuencias temporales (LSTM)
- Real-time scoring en interacciones

Para la Organización:

- Capacitación en data-driven decisions
 - Centro de Excelencia en Analytics
 - Cultura de experimentación (A/B testing)
-

Preguntas y Respuestas

Espacio para Preguntas

Equipo de Proyecto: - Data Science Lead - Business Analyst - ML Engineer

Contacto: - datascience@financeguard.com - Slack: #churn-prediction - Dashboard: analytics.financeguard.com/churn

Gracias

FinanceGuard Bank

Proyecto de Predicción de Churn

Entregables Disponibles: - Reporte técnico completo (Reporte_Modelos.md)
- 4 Jupyter Notebooks ejecutables - 7 visualizaciones profesionales - Código fuente y modelos entrenados - Dashboard interactivo (próximamente)

¿Listo para transformar la retención de clientes?